

基于多模态大语言模型的数字电路时序图解析

本科毕业论文答辩



汤秉达

清华大学 计算机科学与技术系

指导教师：喻文健 教授

2026 年 6 月

提纲

- ① 研究背景与动机
- ② 方法框架
- ③ 数据合成与质量保障
- ④ 评价指标
- ⑤ 模型训练
- ⑥ 实验结果
- ⑦ 总结与展望


研究背景

数字电路时序图是芯片设计中定义模块行为的核心视觉规范：

- 编码信号间的先后次序与因果关系
- 广泛用于协议规范（SPI、I2C、AXI 等）
- 是设计者实现 HDL 代码的权威依据

现状痛点：

- 从时序图到 HDL 代码**完全依赖手工**
- 效率低下：复杂协议需数小时人工解读
- 容易出错：细微依赖关系极易被遗漏



UART 控制器时序图示例

技术机遇与挑战

技术机遇：多模态大语言模型（MLLM）的快速发展

- LLM 在代码生成任务上已展现强大能力
- MLLM 具备从视觉输入提取结构化信息的基础能力

核心挑战：

- ❶ 数据匮乏——不存在面向时序图解析的高质量标注数据集
- ❷ 评价缺失——传统文本相似度指标（BLEU/ROUGE）无法衡量结构语义正确性
- ❸ 领域特化——时序图视觉特征高度专业化，通用模型零样本效果差
- ❹ 功能正确性——仅靠有监督学习难以保证生成代码的功能行为

已有工作与不足

TD-Magic (He et al., 2023)

基于规则从时序图提取偏序关系，难以扩展到复杂场景


TD-Interpreter (He et al., 2025)

对 LLaVA 微调的视觉问答系统，存在以下局限：

- 定位为问答，**不涉及结构化提取与 HDL 代码生成**
- 训练数据采用随机激励，时序图缺乏有意义的功能模式
- 评价仅用 BLEU/ROUGE，缺乏专用评价方法
- 仅 SFT 训练，未探索强化学习优化

⇒ 本文：图像 → 结构化表示 → **HDL** 代码的生成式流水线

框架概览



两阶段设计动机

第一阶段：图像 → WaveJSON

- 模型：Qwen3-VL-4B-Instruct
- 核心能力：跨模态视觉理解
- 需要多模态感知图像中的信号名、波形、数据标签

第二阶段：WaveJSON → Verilog

- 模型：Qwen3-8B
- 核心能力：逻辑推理与代码生成
- 从行为描述推断因果逻辑并转化为电路代码

解耦的优势：

- 两阶段可独立训练与优化，降低学习难度
- 结构化中间表示缩短序列长度，降低显存需求
- 各阶段可选用最合适的模型架构

数据合成链路

从 Verilog 源代码自动产出训练三元组（图像、WaveJSON、Verilog）：



数据源：Verilog_GitHub 数据集

108,971 个文件 → 筛选后 5,847 个有效模块

关键优化点：

- 测试平台生成策略
- 多层级数据质量过滤
- 防泄漏数据划分

测试平台生成：随机激励 vs LLM 激励

基线：随机激励 (gentbvlog)


- 自动生成伪随机输入序列
- 优势：完全自动化、适用面广
- 局限：缺乏功能语义
- 信号行为退化为常量或噪声



左：随机激励（仅触发部分状态）

优化：LLM 激励 (GPT-OSS-120B)

- 分析模块功能后生成针对性激励
- 遍历状态机转移路径
- 测试计数器边界溢出
- 覆盖算术单元典型运算模式



右：LLM 激励（遍历全部状态转移）

数据质量过滤与防泄漏划分

多层次质量过滤：

① Verilog 源码预筛

- 排除含 ``include`、`$readmemh` 的文件
- 排除空壳模块、多模块文件
- 排除工艺库标准单元
- Icarus Verilog 语法检查

② 仿真产出质量筛选

- 图像尺寸与宽高比约束
- 信号数量上下界

防泄漏数据划分：

基于并查集（DSU）的等价类划分：

- WaveJSON 指纹匹配
- 信号名模糊匹配（阈值 0.88）
- 同一等价类**整组分配**到同一集合

划分结果：

训练集 5,730 / 测试集 117

专用评价指标设计

传统文本指标的失效：对语义无关差异过度惩罚，对语义错误不够敏感

本文指标流程：

- ① 信号匹配：精确匹配（规范化信号名）+ 模糊匹配（Levenshtein 距离，阈值 0.7）
- ② 波形评分：
 - 词元模式：展开保持符号后逐周期比较
 - 边沿模式：提取跳变位置与目标电平进行比较
- ③ 综合评分：汇总为精确率 P、召回率 R、F1

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

指标有效性验证

编号	场景	Levenshtein	BLEU	本文 F1
1	信号顺序置换（语义一致）	0.912	0.952	1.000
2	保持符号等价（语义一致）	0.939	0.845	1.000
3a	少量数据标签错误（1/4）	0.991	0.928	0.875
3b	大量数据标签错误（4/4）	0.966	0.777	0.500
4	信号缺失（4 缺 1）	0.897	0.801	0.857

- 场景 1-2：传统指标**虚低**（语义一致但文本不同），本文指标正确满分
- 场景 3：传统指标对错误严重程度**区分力不足**，本文指标差异 0.375
- 场景 4：P/R 分解提供诊断信息（ $P=1.0$, $R=0.75$ ）

有监督微调 (SFT)

第一阶段 SFT

- 基座: Qwen3-VL-4B-Instruct
- 方法: LoRA (秩 32)
- 冻结视觉编码器
- 图像最大像素 1024×1024
- 序列长度 8196 tokens
- 学习率 1×10^{-4}
- 训练 20 Epoch

第二阶段 SFT


- 基座: Qwen3-8B
- 方法: LoRA (秩 64)
- FSDP 分布式训练
- 序列长度 8192 tokens
- 学习率 2×10^{-5}
- 训练 30 Epoch

训练框架: LlamaFactory, BF16 混合精度

基于强化学习的优化（GRPO）

动机：SFT 的词元级损失不直接优化功能正确性

方法：群体相对策略优化（GRPO）+ 仿真奖励



- 奖励 = 仿真对拍 F1 分数 $\in [0, 1]$ （编译失败为 0）
- 每样本采样 4 个候选，组内相对排名估计优势函数
- 连续值奖励提供比二值判定更细粒度的优化梯度

第一阶段结果：图像 → WaveJSON

模型	参数量	解析成功	平均 F1
Qwen3-VL Plus	未公开	88/117	0.226
Qwen3-VL-235B-A22B-Instruct	235B	75/117	0.298
Qwen3-VL-235B-A22B-Thinking	235B	103/117	0.334
Qwen3-VL-4B-Instruct（未微调）	4B	16/117	0.006
Qwen3-VL-4B + SFT（本文）	4B	116/117	0.969

- 99.1% 样本成功解析
- 62.4% 样本 $F1 = 1.0$
- 87.2% 样本 $F1 \geq 0.95$
- **4B** 微调模型远超 **235B** 通用模型
- 验证了领域微调的必要性
- 高质量数据 > 模型规模

第二阶段结果：WaveJSON → Verilog

模型	参数量	通过仿真	平均 F1
GLM-4.5-Air	106B	35/117	0.253
DeepSeek V4 Flash	284B	40/117	0.280
Qwen3-Coder-480B-A35B	480B	47/117	0.321
GPT-OSS-120B	117B	67/117	0.473
Qwen3-8B（未微调）	8B	38/117	0.263
Qwen3-8B + SFT（本文）	8B	79/117	0.614

- 67.5% 通过仿真，其中 51.9% 的 F1=1.0（功能完全正确）
- 8B 微调模型超越 480B 通用模型，领域训练有效性显著
- 仿真成功样本的平均 F1 达到 0.909

强化学习优化效果

模型	通过仿真	平均 F1
Qwen3-8B + SFT	79/117	0.614
Qwen3-8B + SFT + GRPO	89/117	0.630

主要改善：

- 仿真通过率 67.5% $\rightarrow$ 76.1%
- 19 个样本从失败转为成功
- 整体 F1 提升 0.614 $\rightarrow$ 0.630

$\Rightarrow$ 仿真奖励引导模型学会“可编译优先”的生成策略

典型案例：

- 超声脉冲控制器：0 $\rightarrow$ 0.951
- 存储器仲裁状态机：0 $\rightarrow$ 0.936
- 处理器程序计数器：0 $\rightarrow$ 0.854

❶ 优化数据合成链路

- LLM 替代随机激励生成高质量测试平台
- 多层次质量过滤 + 防泄漏数据划分

❷ 专用评价指标

- 基于信号级匹配的 P/R/F1 评分，同时作为 RL 奖励函数

❸ 两阶段有监督微调

- 4B 视觉模型 $F1=0.969$ ，8B 文本模型 $F1=0.614$
- 小参数模型远超通用大模型

❹ 基于仿真奖励的强化学习

- GRPO 闭环优化，仿真通过率 $67.5\% \rightarrow 76.1\%$

局限性与未来方向

局限性：

- 仅验证了 WaveDrom 风格时序图，对 EDA 工具截图/手绘草图的泛化能力未知
- 两阶段存在误差传播风险，缺乏跨阶段纠错机制
- 大规模复杂时序图的处理能力有待提升

未来方向：

- ① 端到端单阶段架构或跨阶段反馈机制
- ② 从时序图自动生成 SystemVerilog 断言
- ③ 设计文档与 RTL 实现的一致性检查
- ④ 集成到实际 EDA 工具链

谢谢！

敬请各位老师批评指正

汤秉达 清华大学计算机科学与技术系

指导教师：喻文健 教授